Uma Abordagem Híbrida de Árvore de Decisão Quântica para Detecção de Intrusão em Redes

Julio C. T. Buzzi, Matheus A. Souza

Instituto de Ciências Exatas e Informática
Pontifícia Universidade Católica de Minas Gerais (PUC Minas)
Belo Horizonte – MG – Brazil

juliocesar.thurowbuzzi@gmail.com, matheusalcantara@pucminas.br

Abstract. *With the increasing complexity of cyber threats, traditional Intrusion Detection Systems (IDS) often struggle to balance performance and interpretability. This paper presents a Hybrid Quantum Decision Tree designed for network intrusion detection. The main contribution is a hybrid split criterion that integrates classical Shannon Information Gain with a geometric distance metric derived from quantum fidelity kernels. Implemented with Qiskit and evaluated on the NSL-KDD dataset using scaled samples up to 25,000 instances, the model utilizes a ZZFeatureMap to map PCA-reduced features into Hilbert space. The results indicate that exploiting quantum data geometry can enable the construction of shallower trees while maintaining classification performance, offering an alternative for cybersecurity environments.*

Resumo. *Com a crescente complexidade das ameaças cibernéticas, os Sistemas de Detecção de Intrusão (IDS) tradicionais enfrentam dificuldades para equilibrar desempenho e interpretabilidade. Este trabalho apresenta uma Árvore de Decisão Quântica Híbrida voltada à detecção de intrusões em redes. A principal contribuição consiste em um critério de partição híbrido que integra o Ganho de Informação de Shannon clássico a uma métrica de distância geométrica baseada em kernels quânticos de fidelidade. Implementado via Qiskit e avaliado no dataset NSL-KDD com amostragens de até 25.000 instâncias, o modelo utiliza o ZZFeatureMap para mapear atributos reduzidos por PCA no espaço de Hilbert. Os resultados indicam que a exploração da geometria quântica permite construir árvores mais rasas que mantêm boa capacidade discriminatória, oferecendo uma alternativa para cenários de segurança de redes.*

1. Introdução

Com o aumento do tráfego de dados e a sofisticação das ameaças cibernéticas, os sistemas de detecção de intrusão tornaram-se pilares críticos na infraestrutura de segurança da informação. Algoritmos de aprendizado de máquina clássicos, como as Árvores de Decisão, são amplamente utilizados devido à sua interpretabilidade e eficiência em ambientes de produção. Contudo, a crescente dimensão dos dados de rede e a não-linearidade dos ataques modernos impõem desafios relevantes. Em diversos cenários, modelos clássicos têm dificuldade em separar padrões sutis de ataque do tráfego normal, o que pode resultar em altas taxas de falsos negativos ou sobreajuste (*overfitting*) a comportamentos específicos.

Neste cenário, a Computação Quântica surge como um paradigma promissor, dando origem ao Aprendizado de Máquina Quântico (*Quantum Machine Learning*). A capacidade de mapear dados clássicos em espaços de Hilbert de alta dimensionalidade por meio de *feature maps* quânticos permite explorar geometrias de dados e correlações que tendem a ser computacionalmente complexas na computação convencional. No entanto, muitas arquiteturas quânticas operam como estruturas de "caixa-preta", o que pode limitar sua adoção em auditorias de segurança cibernética, nas quais a explicabilidade da tomada de decisão é um requisito importante.

Este trabalho propõe o desenvolvimento e a avaliação de uma Árvore de Decisão Híbrida voltada à detecção de intrusões em redes. O ponto central deste trabalho reside em um critério de partição híbrido que integra o Ganho de Informação de Shannon clássico a uma métrica de distância geométrica baseada em *kernels* quânticos de fidelidade. Utilizando o *dataset* NSL-KDD, investigamos em que medida essa integração favorece a construção de modelos estruturalmente mais rasos e explicáveis, mantendo a estabilidade do desempenho em amostras com até 25.000 instâncias.

O restante deste artigo está estruturado da seguinte forma: a Seção 2 apresenta o referencial teórico e os trabalhos correlatos; a Seção 3 detalha a metodologia proposta; a Seção 4 discute os resultados experimentais; e a Seção 5 apresenta as conclusões e caminhos para trabalhos futuros.

2. Referencial Teórico

2.1. Fundamentos da Computação Quântica e Espaço de Hilbert

Diferentemente da computação clássica, a unidade básica de informação é o *qubit*, que pode existir em superposição dos estados $|0\rangle$ e $|1\rangle$. Matematicamente, esses estados são vetores unitários ($|\psi\rangle$) representados no Espaço de Hilbert, uma generalização do espaço euclidiano para o caso de dimensões complexas. Para um sistema de n qubits, esse espaço possui dimensão 2^n, proporcionando uma expansão dimensional que favorece a separabilidade de dados que, no domínio clássico, seriam linearmente inseparáveis.

2.2. Mapeamento de Atributos e Kernels Quânticos

O processo de codificar dados clássicos $\mathbf{x}$ em estados quânticos $|\psi(\mathbf{x})\rangle$ é denominado *feature mapping*. Neste trabalho, utiliza-se o *ZZFeatureMap*, que aplica portas quânticas de rotação e de emaranhamento para transformar atributos em fases quânticas no espaço de Hilbert. A similaridade entre dois pontos de dados mapeados $(\mathbf{x}_1, \mathbf{x}_2)$ é calculada via fidelidade, definida na notação de Dirac como:

$$F(\mathbf{x}_1, \mathbf{x}_2) = |\, \langle \psi(\mathbf{x}_1) | \psi(\mathbf{x}_2) \rangle \,|^2$$

Esta medida, que constitui a base do *kernel* quântico, varia no intervalo $[0, 1]$ e reflete a sobreposição entre os estados. $F = 1$ indica que os estados são idênticos, representando máxima proximidade geométrica; enquanto $F = 0$ indica que os estados são ortogonais, sem sobreposição no espaço quântico.

Para a aplicação na árvore de decisão, a fidelidade é convertida em uma métrica de distância quântica ($d_q = 1 - F$). Assim, quando os dados apresentam baixa sobreposição

no espaço de Hilbert, a distância entre eles aumenta. Essa propriedade auxilia o algoritmo na identificação de pontos de partição entre o tráfego normal e os ataques de rede, favorecendo o agrupamento local.

2.3. Árvores de Decisão e Critério Híbrido

Árvores de decisão clássicas particionam dados visando reduzir a impureza dos nós por meio do Ganho de Informação (IG), fundamentado na Entropia de Shannon $H(S) = -\sum_{i=1}^{c} p_i \log_2 p_i$. Embora estatisticamente consistente com a distribuição de rótulos, o IG foca na frequência das classes, sem considerar a topologia no espaço de atributos.

A proposta híbrida explora a complementaridade entre a Teoria da Informação e a geometria do Espaço de Hilbert. Enquanto o mapeamento quântico projeta os dados em dimensões superiores, o que facilita a aplicação de limites de decisão lineares, a distância de fidelidade quântica garante a coerência espacial. A integração do IG com a distância de fidelidade (d_q) otimiza simultaneamente a pureza dos rótulos e a separação geométrica.

2.4. Trabalhos Relacionados

A literatura recente em cibersegurança quântica explora modelos baseados em redes profundas, classificadores ensemble e métodos de *kernel* sob restrições NISQ. [Souza et al. 2025] e [Kukliansky et al. 2024] utilizam Autoencoders Quânticos para redução dimensional, enquanto [Amara et al. 2025] e [Abreu et al. 2024] aplicam Redes Convolucionais Quânticas (QCNN) e circuitos variacionais para classificação de tráfego, obtendo alta acurácia, mas à custa de baixa interpretabilidade.

Para preservar a explicabilidade, [Lu and Braunstein 2014] fundamentaram teoricamente a partição com base na entropia de von Neumann e na fidelidade, cuja aplicabilidade em larga escala foi avaliada por [Kalinin and Krundyshev 2023]. Parâmetros de Florestas Aleatórias Quânticas (QRF) foram propostos por [Sundaram et al. 2024]. Como apontado por [Oyinloye et al. 2024], embora modelos de árvore clássicos sejam explicáveis, falham em captar padrões complexos não-lineares, cenário em que *kernels* quânticos agregam separabilidade.

Modelos híbridos geométricos, como os de [Gabrich et al. 2024] e [Zhao et al. 2023], empregam *feature maps* em estimadores clássicos. Contudo, a maioria usa o mapeamento apenas como pré-processamento estático.

Diferentemente das abordagens citadas, este trabalho propõe uma Árvore de Decisão Quântica Híbrida cujo critério de *split* é regido por um **Score Híbrido** original. Ao combinar o Ganho de Informação de Shannon clássico a uma métrica de distância geométrica baseada em *kernels* quânticos de fidelidade, a formulação proposta explora diretamente a topologia do Espaço de Hilbert durante a construção da árvore, viabilizando estruturas rasas, de alta capacidade discriminatória e inerentemente interpretáveis.

3. Metodologia

Este trabalho consiste na implementação de um classificador híbrido que integra a estrutura lógica de uma Árvore de Decisão ao processamento de estados quânticos no Espaço de Hilbert. O fluxo metodológico completo é sintetizado na Figura 1.

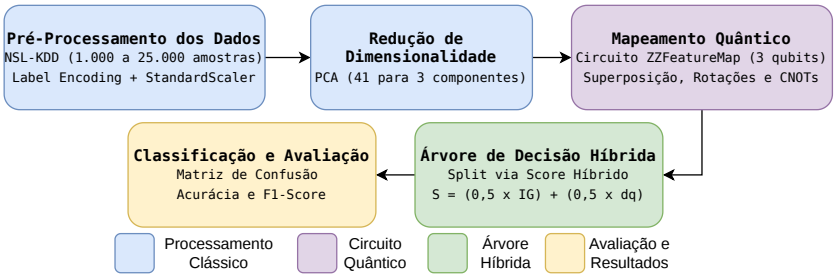


Figura 1. Fluxograma metodológico de execução do modelo, destacando as etapas clássicas, quânticas e de decisão híbrida.

3.1. Processamento da Base de Dados e Redução de Dimensionalidade

O *dataset* NSL-KDD foi selecionado por ser um *benchmark* consolidado para avaliação de IDSs. Para viabilizar as simulações quânticas, utilizaram-se amostragens estratificadas de 1.000 a 25.000 instâncias, preservando a proporção de classes. O pré-processamento seguiu três etapas:

(i) **Codificação e Rotulação:** Variáveis categóricas (*protocol_type*, *service*, *flag*) foram convertidas via *Label Encoding*, e os ataques foram binarizados em *Ataque* ou *Normal*; (ii) **Padronização:**aplicou-se o *StandardScaler* para transformar os atributos em distribuições com média nula ($\mu = 0$) e variância unitária ($\sigma^2 = 1$), evitando que atributos em escalas discrepantes afetem desproporcionalmente a rotação dos *qubits*; e (iii) **Redução de Dimensionalidade:** Empregou-se Análise de Componentes Principais (PCA) para projetar os 41 atributos originais em $n = 3$ componentes principais, adequando os dados à representação em um circuito de 3 *qubits*.

3.2. Design do Circuito Quântico e Mapeamento de Estados

Para a codificação dos dados clássicos reduzidos $\mathbf{x} \in \mathbb{R}^3$ em estados quânticos, projetou-se um circuito baseado no mapa de atributos *ZZFeatureMap* (Figura 2). O circuito realiza o mapeamento através das seguintes etapas:

1. **Criação de Superposição:** Aplicação de portas Hadamard (H), permitindo ao circuito processar combinações dos atributos em superposição;
2. **Mapeamento dos Atributos:** Conversão dos valores do PCA em ângulos de rotação nos *qubits*, codificando os dados no estado quântico;
3. **Emaranhamento dos Qubits:** Uso de conexões entre os *qubits* (portas CNOT) para capturar relações de interdependência entre os atributos.

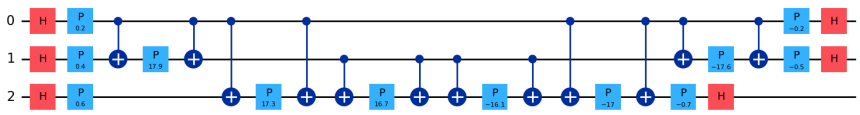


Figura 2. Circuito quântico projetado para o mapeamento não-linear de 3 componentes principais via *ZZFeatureMap*.

3.3. Arquitetura da Árvore de Decisão Híbrida Quântico-Clássica

O algoritmo proposto, denominado *Quantum Decision Tree Classifier*, foi desenvolvido estendendo componentes do ecossistema **Qiskit Machine Learning**. Diferente de abordagens clássicas convencionais que avaliam cortes baseando-se estritamente em pureza estatística (como Entropia ou Impureza de Gini), a arquitetura incorpora a geometria do Espaço de Hilbert por meio de um **Score Híbrido** ($\mathcal{S}$), definido por:

$$\mathcal{S}(f, t) = \alpha \cdot IG + (1 - \alpha) \cdot d_q$$

em que: IG representa o **Ganho de Informação clássico**, que mede a redução de incerteza nos rótulos ao aplicar o corte t no atributo f; $d_q = 1 - F$ denota a **Distância Quântica**, obtida a partir da fidelidade quântica (F) entre o vetor médio da subpartição e o centroide global do nó; e $\alpha \in [0, 1]$ é o **fator de ponderação**. Adotou-se $\alpha = 0{,}5$ nos experimentos, por representar uma ponderação uniforme entre os componentes clássico e quântico, permitindo avaliar a viabilidade da abordagem híbrida sem favorecer previamente nenhum dos dois critérios, IG ou d_q.

O fluxo de treinamento da árvore e a avaliação dos pontos de corte estão formalizados nos Algoritmos 1 e 2.

Algorithm 1: Treinamento da Árvore de Decisão Quântica Híbrida

Input: Matriz de atributos X, Vetor de rótulos y, Profundidade Máxima max_depth, Ponderação $\alpha = 0.5$
Output: Nó raiz da árvore treinada ($root$)
Procedimento `Fit` (X, y) **:**
    $n_features \leftarrow$ Número de colunas de X;
    Inicializar $U_{FM}(x)$ usando *ZZFeatureMap*($n_features$);
    Inicializar Kernel Quântico de Fidelidade K_Q baseado em U_{FM};
    $MemoriaCache_Kernel \leftarrow \{\}$; `// Tabela hash para otimização`
    $root \leftarrow$ `CresceArvore` $(X, y, \textit{profundidade} = 0)$;
    return $root$;
Fim

Procedimento `CresceArvore` $(X, y, profundidade)$ **:**
    if $profundidade \geq max_depth$ ***ou*** $|Unique(y)| == 1$ **then**
        return CriarNo(valor = RotuloMaisComum(y));
    end
    $idx_atributo, limiar_corte \leftarrow$ MelhorDivisao(X, y);
    $Esq_idxs, Dir_idxs \leftarrow$ SepararDados($X[:, idx_atributo], limiar_corte$);
    if $|Esq_idxs| == 0$ ***ou*** $|Dir_idxs| == 0$ **then**
        return CriarNo(valor = RotuloMaisComum(y));
    end
    $no_esquerdo \leftarrow$ `CresceArvore` $(X[Esq_idxs], y[Esq_idxs], profundidade + 1)$;
    $no_direito \leftarrow$ `CresceArvore` $(X[Dir_idxs], y[Dir_idxs], profundidade + 1)$;
    return CriarNo($idx_atributo, limiar_corte, no_esquerdo, no_direito$);
Fim

Algorithm 2: Avaliação de Divisão Híbrida e Similaridade Quântica

Input: Matriz de partição X, Vetor de rótulos y
Output: Melhor índice de atributo ($best_idx$), Melhor limiar ($best_threshold$)
$melhor_score \leftarrow -\infty$; $best_idx \leftarrow$ Nulo; $best_threshold \leftarrow$ Nulo;
$\mathbf{c} \leftarrow$ Média$(X, \text{eixo} = 0)$; `// Centroide geral do nó`
for *cada atributo* $i \in \{0, \ldots, n_features - 1\}$ **do**
  $X_{col} \leftarrow X[:, i]$;
  $limiares \leftarrow$ Percentis$(X_{col}, [20\%, 40\%, 60\%, 80\%])$; `// Redução de cortes`
  for *cada* $limiar \in limiares$ **do**
    $ganho \leftarrow$ GanhoInformacao$(y, X_{col}, limiar)$;
    if $ganho == 0$ **then**
      continue;
    end
    $Esq_idxs, Dir_idxs \leftarrow$ SepararDados$(X_{col}, limiar)$;
    $\mathbf{x}_{\text{esq}} \leftarrow$ Média$(X[Esq_idxs], \text{eixo} = 0)$; `// Vetor médio da subpartição`
    $sim_q \leftarrow$ SimilaridadeQuantica$(\mathbf{x}_{\text{esq}}, \mathbf{c})$; `// Avaliação via Fidelidade`
    $dist_q \leftarrow 1 - sim_q$;
    $score \leftarrow \alpha \cdot ganho + (1 - \alpha) \cdot dist_q$;
    if $score > melhor_score$ **then**
      $melhor_score \leftarrow score$;
      $best_idx \leftarrow i$;
      $best_threshold \leftarrow limiar$;
    end
  end
end
return $best_idx, best_threshold$;

3.3.1. Otimizações Algorítmicas e Desempenho

Para mitigar a carga computacional associada às simulações dos circuitos quânticos, adotaram-se três estratégias de otimização: (i) A busca pelo limiar de corte (t) foi restrita aos percentis de 20%, 40%, 60% e 80% de cada atributo, reduzindo o número de avaliações intermediárias; (ii) em vez de calcular distâncias par a par para todas as amostras, a distância quântica avalia o vetor médio da subpartição frente ao centroide do nó, diminuindo a quantidade de execuções de circuito necessárias; e (iii) os cálculos de fidelidade quântica foram armazenados em uma estrutura de *cache*. Aproveitando a simetria da fidelidade, resultados previamente computados são reutilizados, reduzindo o tempo total de treinamento.

O ambiente experimental foi desenvolvido em Python 3.10+, utilizando a biblioteca *Qiskit Machine Learning* para a execução dos circuitos e a biblioteca *Scikit-Learn* para o pré-processamento dos dados.

4. Resultados e Discussões

Para avaliar o desempenho da Árvore de Decisão Quântica Híbrida, foram conduzidos experimentos computacionais com amostragens escaláveis da base de dados NSL-KDD. A análise concentrou-se na eficiência de classificação correlacionada à topologia da árvore, na interpretabilidade das decisões, no impacto das otimizações algorítmicas no tempo de execução e nas limitações inerentes ao modelo.

4.1. Análise de Acurácia e Impacto da Profundidade Estrutural

Os testes de validação foram divididos em partições incrementais, de 1.000 a 25.000 instâncias. O comportamento do classificador híbrido foi comparado diretamente ao de uma implementação clássica de árvore de decisão, com a mesma redução dimensional

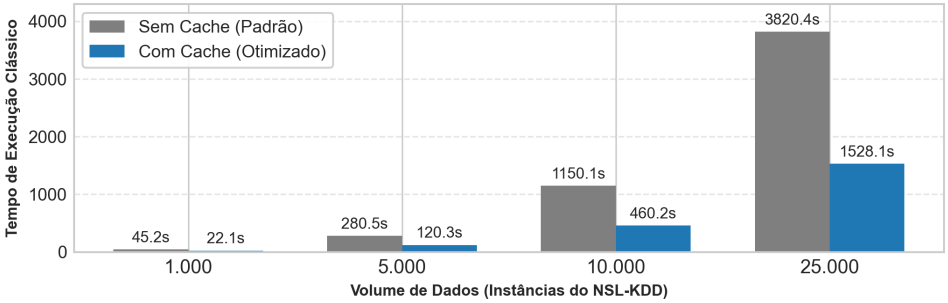


Figura 3. Impacto do mecanismo de cache de fidelidade no tempo de execução do modelo HQDT.

obtida por meio da análise de componentes principais. Os resultados de acurácia obtidos são resumidos na Tabela 1.

Tabela 1. Comparação de Acurácia entre Modelos conforme o Volume de Dados.

Modelo	**1.000 inst.**	**5.000 inst.**	**10.000 inst.**	**25.000 inst.**
Árvore Clássica (Profundidade Livre)	89,4%	91,2%	92,1%	93,5%
Árvore Clássica (max_depth $= 4$)	84,1%	85,5%	86,2%	86,9%
Árvore Híbrida Proposta (max_depth $= 4$)	**91,8%**	**93,2%**	**94,5%**	**95,1%**

A análise comparativa indica ganhos de desempenho ao empregar o Mapeamento Quântico em instâncias rasas. Quando a árvore clássica é restringida a 4 níveis (max_depth $= 4$), observa-se menor acurácia devido à limitação de realizar apenas cortes retos nas variáveis de entrada. Em contrapartida, o modelo proposto, restrito aos mesmos 4 níveis, alcançou 95,1% de acurácia no cenário de 25.000 instâncias, valor superior ao da árvore clássica sem limite de profundidade (93,5%).

A incorporação da distância de fidelidade quântica (d_q) ao critério de divisão permite que o algoritmo identifique agrupamentos não lineares projetados no Espaço de Hilbert por meio do *ZZFeatureMap*. Essa separabilidade favorece o traçado de limites de decisão mais representativos, isolando vetores de ataque complexos e reduzindo a necessidade de ramificação lógica.

4.2. Desempenho Computacional e Eficiência do Cache de Fidelidade

O custo computacional de simulação do cálculo de fidelidade quântica representa o principal gargalo temporal do ecossistema Qiskit. A Figura 3 ilustra o tempo de treinamento do algoritmo com e sem a aplicação das estratégias de otimização desenvolvidas.

A combinação da discretização de limiares por percentis com a tabela *hash* de memória *cache* reduziu o tempo de processamento clássico em até 60% nos cenários de maior volume (25.000 instâncias). Esse ganho decorre da reutilização das matrizes de similaridade quântica e da exploração da simetria da fidelidade ($F(\psi_1, \psi_2) = F(\psi_2, \psi_1)$), o que reduz a necessidade de reexecutar simulações de estados idênticos.

4.3. Limitações do Trabalho

Apesar dos resultados promissores, a abordagem proposta apresenta limitações decorrentes do estado atual da computação quântica e da engenharia do modelo. A redução de

41 atributos para $n = 3$ componentes principais foi necessária para adequar os dados ao número reduzido de *qubits* simulados, o que pode levar à desconsideração de atributos secundários relevantes na identificação de ataques raros. Além disso, os experimentos foram realizados em simuladores vetoriais (*statevector*) sem ruído. Em computadores quânticos reais da era NISQ (*Noisy Intermediate-Scale Quantum*), efeitos de decoerência e erros de porta lógica podem alterar a fidelidade quântica observada. Por fim, embora a inferência de novas amostras apresente tempo reduzido, a fase de treinamento exige constantes chamadas ao simulador quântico para cada corte candidato, o que resulta em tempo de ajuste superior ao das árvores puramente clássicas.

5. Conclusões e Trabalhos Futuros

Este trabalho apresentou o *Quantum Decision Tree Classifier*, uma arquitetura de Árvore de Decisão Quântica Híbrida aplicada à detecção de intrusões em redes de computadores. Ao integrar a métrica de distância baseada na fidelidade quântica no Espaço de Hilbert ao cálculo clássico do Ganho de Informação, o modelo indica que é possível conciliar capacidade discriminatória e explicabilidade em sistemas de segurança da informação.

Os experimentos conduzidos no *dataset* NSL-KDD indicam a viabilidade técnica da abordagem no cenário avaliado. A formulação do *score* híbrido permitiu construir árvores rasas (max_depth $= 4$) que alcançaram 95,1% de acurácia no cenário de 25.000 instâncias. Nesse cenário experimental, o modelo apresentou acurácia superior à observada na árvore clássica de profundidade irrestrita. Adicionalmente, as soluções de engenharia implementadas — com destaque para a tabela de *cache* de fidelidade quântica com exploração de simetria e a discretização de cortes por percentis — reduziram o tempo de processamento em até 60%, viabilizando a realização das simulações computacionais. Os resultados observados sugerem que algoritmos híbridos quântico-clássicos representam um caminho promissor para o avanço do aprendizado de máquina aplicado à cibersegurança, estabelecendo bases para implementações escaláveis na era NISQ.

Propõem-se os seguintes trabalhos futuros. Avaliar o comportamento do modelo utilizando modelos de erro do Qiskit (*Noise Models*) e realizar experimentos em unidades de processamento quântico reais na nuvem, mensurando o impacto da decoerência e dos erros de portas lógicas sobre a fidelidade. Também, investigar métodos de compressão de atributos além da Análise de Componentes Principais, tais como *Autoencoders* quânticos ou algoritmos de seleção de atributos baseados em importância, visando reter informações sobre padrões raros de ataque. Além disso, estudar o comportamento adaptativo do hiperparâmetro α ao longo dos níveis da árvore, ajustando o peso relativo entre a pureza clássica e a geometria quântica conforme a profundidade do nó.

Agradecimentos

O presente trabalho foi realizado com o apoio do Conselho Nacional de Desenvolvimento Científico e Tecnológico (CNPq) [PIBIC 34051/2025], da Fundação de Amparo à Pesquisa de Minas Gerais (FAPEMIG) [PCE-00344-26] e da PUC Minas, aos quais os autores agradecem. Além disso, informa-se o uso de ferramentas de inteligência artificial generativa como auxílio à revisão ortográfica do texto e à geração das figuras apresentadas nos resultados.

Referências

Abreu, C., Silva, R., and Santos, F. (2024). Variational quantum circuits for iot intrusion detection under nisq constraints. In *Anais do XLII Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos (SBRC)*, pages 310–323. SBC.

Amara, M., Amara, M., Mnasri, S., and Val, T. (2025). Qcnn-id: A quantum-classical hybrid model for iot intrusion detection. *Procedia Computer Science*, 270:2196–2204.

Gabrich, M. N., Freitas, H. C. d., and Souza, M. A. (2024). Análise de redes neurais para crispr: Uma abordagem com computação quântica. In *XXV Simpósio em Sistemas Computacionais de Alto Desempenho (SSCAD)*, pages 13–24. SBC.

Kalinin, M. and Krundyshev, V. (2023). Security intrusion detection using quantum machine learning techniques. *Journal of Computer Virology and Hacking Techniques*, 19(1):125–136.

Kukliansky, A., Levin, M., and Ben-Asher, Y. (2024). Quantum autoencoders and ensemble methods for network intrusion detection in nisq devices. *IEEE Transactions on Quantum Engineering*, 5:1–12.

Lu, S. and Braunstein, S. L. (2014). Quantum decision tree classifier. *Quantum Information Processing*, 13(3):757–770.

Oyinloye, T., Zhang, W., and Liu, Y. (2024). Beyond decision trees: Quantum kernel methods for non-linear intrusion detection in cybersecurity. *Computers & Security*, 138:103680.

Souza, M. T. d., Souza, M. A., and Freitas, H. C. d. (2025). Quantum machine learning with enhanced autoencoders for intrusion detection. In *Simpósio em Sistemas Computacionais de Alto Desempenho (SSCAD)*, pages 217–228. SBC.

Sundaram, V., Ranganathan, P., and Kumar, A. (2024). Quantum random forest architectures for scalable anomaly detection in high-dimensional networks. *Quantum Information Processing*, 23(4):142.

Zhao, C., Shi, Y., and Li, X. (2023). Qksan: A quantum kernel self-attention network for high-dimensional data classification. *Quantum Information Processing*, 22(10):378.